



Universidade de Brasília



Laboratório
Compartilhado de Ensino e
Pesquisa em Telecomunicações

Conversão Analógico-Digital

Capítulo 7 (Proakis) e Capítulo 5 (Lathi)

Prof. Daniel Costa Araújo

Universidade de Brasília
Laboratório de Telecomunicações

February 19, 2026



Sumário

- 1 Amostragem
- 2 Quantização
- 3 PCM e Companding

Capítulo 7

Conversão Analógico-Digital

Amostragem, Quantização, PCM e Companding



Por Que Digitalizar Sinais?

O mundo é analógico:

- Voz humana → pressão de ar contínua
- Música → ondas mecânicas
- Temperatura, pressão, tensão elétrica...

Computadores só entendem 0 e 1.

Precisamos **converter** o sinal analógico para digital (ADC).

Aplicações cotidianas:

- **Telefonia:** $f_s = 8 \text{ kHz}$, 8 bits
- **CD de áudio:** $f_s = 44,1 \text{ kHz}$, 16 bits
- **Wi-Fi / 5G:** ADC em GHz!

Cadeia ADC — 3 etapas:

- 1 Amostragem
- 2 Quantização
- 3 Codificação (PCM)



Modelo Matemático do Amostrador Ideal

Seja $g(t)$ um sinal **passa-baixas limitado em banda**:

$$G(f) = 0 \quad \text{para } |f| \geq W$$

O amostrador ideal multiplica $g(t)$ por um **trem de impulsos de Dirac** (“pente”) espaçado de T_s :

$$\delta_{T_s}(t) = \sum_{n=-\infty}^{\infty} \delta(t - nT_s) \quad T_s = \frac{1}{f_s}$$

O **sinal amostrado** resultante é:

$$g_s(t) = g(t) \cdot \delta_{T_s}(t)$$

Questão fundamental: qual o menor f_c que ainda permite reconstruir $g(t)$ com perfeição?



Derivação — Passo 1: Sinal Amostrado no Tempo

Expandindo $g_s(t)$ com a definição do trem de impulsos:

$$g_s(t) = g(t) \cdot \sum_{n=-\infty}^{\infty} \delta(t - nT_s) = \sum_{n=-\infty}^{\infty} g(t) \delta(t - nT_s)$$

Usamos a **propriedade de filtragem** da delta de Dirac:

$$x(t) \delta(t - t_0) = x(t_0) \delta(t - t_0)$$

O impulso em t_0 “captura” o valor $x(t_0)$ e descarta todo o resto do sinal.

Aplicando a cada termo da soma:

$$g_s(t) = \sum_{n=-\infty}^{\infty} g(nT_s) \delta(t - nT_s)$$



Derivação — Passo 2: Transformada de Fourier e Convolução

No domínio da frequência, **multiplicação no tempo** equivale a **convolução na frequência**:

$$G_s(f) = \mathcal{F}\{g_s(t)\} = \mathcal{F}\{g(t) \cdot \delta_{T_s}(t)\} = G(f) * \mathcal{F}\{\delta_{T_s}(t)\}$$

Para completar, precisamos calcular $\mathcal{F}\{\delta_{T_s}(t)\}$ — a transformada do trem de impulsos.

Passo 3 — Transformada do Trem de Impulsos

O trem de impulsos é periódico com período T_s . Desenvolvendo-o em Série de Fourier exponencial, todos os coeficientes têm o mesmo módulo $1/T_s = f_s$. Portanto:

$$\mathcal{F}\left\{\sum_{n=-\infty}^{\infty} \delta(t - nT_s)\right\} = f_s \sum_{k=-\infty}^{\infty} \delta(f - k f_s)$$

Conclusão: elevar um trem de impulsos no tempo gera outro trem de impulsos na frequência.



Derivação — Passo 4: Convolução com o Trem de Impulsos

Substituindo em $G_s(f) = G(f) * \mathcal{F}\{\delta_{T_s}(t)\}$:

$$G_s(f) = G(f) * \left(f_s \sum_{k=-\infty}^{\infty} \delta(f - k f_s) \right)$$

Pela **distributividade** da convolução, levamos $*$ para dentro do somatório:

$$G_s(f) = f_s \sum_{k=-\infty}^{\infty} G(f) * \delta(f - k f_s)$$

Aplicamos a propriedade de **deslocamento por convolução**:

$$X(f) * \delta(f - f_0) = X(f - f_0)$$



Resultado: Espectro do Sinal Amostrado

Espectro do Sinal Amostrado

$$G_s(f) = f_s \sum_{k=-\infty}^{\infty} G(f - k f_s)$$

O espectro de $g_s(t)$ é uma **soma periódica de réplicas** de $G(f)$, cada uma deslocada de $k f_s$ e escalada por f_s .


Consequências imediatas:

- A amostragem **repete o espectro** a cada f_s Hz.
- Se as réplicas não se sobrepõem, $G(f)$ pode ser isolada com um filtro passa-baixas ideal de corte em W .
- Se houver sobreposição \Rightarrow **aliasing** — distorção irreversível




Visualização do Espectro Amostrado

(a) Sem aliasing: $f_s = 6 \text{ kHz} > 2W = 4 \text{ kHz}$



(b) Com aliasing: $f_s = 3 \text{ kHz} < 2W = 4 \text{ kHz}$





Condição de Nyquist — Derivação

Para reconstrução perfeita, as réplicas **não podem se sobrepor**.

- Réplica em $k = 0$: ocupa $[-W, +W]$
- Réplica em $k = 1$: ocupa $[f_s - W, f_s + W]$

Para que as réplicas em $k = 0$ e $k = 1$ não se sobreponham, o início da réplica em f_s deve estar além do fim da réplica em 0:

$$f_s - W > W \implies f_s > 2W$$

Teorema de Nyquist-Shannon

Um sinal $g(t)$ com espectro limitado a $[-W, W]$ Hz pode ser **perfeitamente reconstruído** a partir de suas amostras $\{g(nT_s)\}$ se, e somente se:



Aliasing: O Que Acontece Quando $f_s < 2W$?

Aliasing = sobreposição das réplicas espectrais.

Efeito prático: uma componente de frequência $f_0 > f_s/2$ “se disfarça” de uma frequência espúria $f_{\text{alias}} = |f_0 - f_s|$ no sinal recuperado.

Exemplo numérico: sinal em $f_0 = 800$ Hz amostrado com $f_s = 900$ Hz.

$$f_{\text{alias}} = |800 - 900| = 100 \text{ Hz} \quad \longleftarrow \quad \text{frequência completamente errada!}$$


Observação: uma vez que o aliasing ocorre, a informação perdida **não pode ser recuperada**.

Solução na prática: inserir um **filtro anti-aliasing** (passa-baixas analógico com corte em $f_s/2$) *antes* do amostrador, garantindo que o sinal seja estritamente limitado em banda.




Aliasing — Demonstração Visual

(a) Amostragem adequada: $f_s = 2500 \text{ Hz} > 2 \cdot 800 = 1600 \text{ Hz}$




(b) Subamostragem: $f_s = 900 \text{ Hz} < 2 \cdot 800 = 1600 \text{ Hz} \rightarrow$ Alias em 100 Hz!





Amostragem no Domínio do Tempo

(a) Sinal original $g(t)$ — contínuo no tempo



(b) Trem de impulsos ($T_s = 33.3$ ms, $f_s = 30$ Hz)





Reconstrução: Filtro Passa-Baixas Ideal

Se $f_s > 2W$, podemos **recuperar** $g(t)$ **exatamente** filtrando $g_s(t)$ com um filtro passa-baixas ideal de corte em W :

$$H(f) = \frac{1}{f_s} \text{rect}\left(\frac{f}{2W}\right) \implies \hat{G}(f) = G_s(f) \cdot H(f) = G(f)$$

No domínio do tempo, o filtro ideal corresponde a um pulso sinc:

$$h(t) = \mathcal{F}^{-1}\{H(f)\} = \frac{2W}{f_s} \text{sinc}(2Wt)$$

A reconstrução completa do sinal contínuo é a **interpolação sinc**:

$$g(t) = \sum_{n=-\infty}^{\infty} g(nT_s) \text{sinc}\left(\frac{t - nT_s}{T_s}\right)$$



Por Que Quantizar?

Após a amostragem, temos $g[n] = g(nT_s)$: discreto no tempo, mas com **amplitude ainda contínua**.

O problema:

- Um processador só armazena valores **discretos**
- Com n bits há apenas 2^n valores representáveis
- Amplitudes contínuas **precisam ser arredondadas**

Analogia cotidiana:

- Régua com marcas a cada 1 mm
- 23,731 mm \rightarrow 23,7 mm
- O erro é inevitável — só reduzível

A questão central:

Conversão Analógico-Digital
Quantização introduz?



O Quantizador Uniforme

Seja $g[n]$ com faixa de amplitude $[V_{\min}, V_{\max}]$.

Dividindo a faixa total $V_{pp} = V_{\max} - V_{\min}$ em L intervalos **iguais**, o tamanho de cada degrau é:

$$\Delta = \frac{V_{pp}}{L}$$

O k -ésimo intervalo cobre $[V_{\min} + k\Delta, V_{\min} + (k+1)\Delta)$ e é mapeado para o seu **ponto médio**:

$$\hat{g}[n] = V_{\min} + \left(k + \frac{1}{2}\right)\Delta, \quad k = 0, 1, \dots, L-1$$

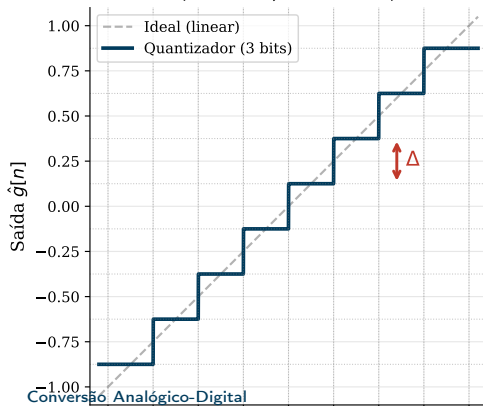
A saída é uma **função escada**: cada amplitude de entrada é arredondada para o nível de quantização mais próximo.

Com n bits podemos representar $L = 2^n$ níveis.




Característica do Quantizador

(a) Característica do Quantizador
($n = 3$ bits, $L = 8$ níveis)



(b) Sinal Original vs. Quantizado
($n = 3$ bits, erro indicado em roxo)





O Erro de Quantização

O erro de quantização é a diferença entre o valor quantizado e o valor real:

$$e_q[n] = \hat{g}[n] - g[n]$$

Como o quantizador mapeia cada amostra para o **ponto médio** de seu intervalo Δ , o erro fica sempre limitado a:

$$-\frac{\Delta}{2} \leq e_q[n] \leq +\frac{\Delta}{2}$$

Compromisso fundamental:

- Erro menor $\Rightarrow \Delta$ menor \Rightarrow mais níveis $L = V_{pp}/\Delta \Rightarrow$ mais bits $n = \log_2 L$
- Aumentar n em 1 bit $\Rightarrow \Delta$ cai pela metade \Rightarrow erro máximo cai pela metade



Modelo Estatístico do Erro de Quantização

Hipóteses do modelo de ruído de quantização (válidas para L grande e sinal variando rapidamente):

- 1 $e_q[n]$ é uma **variável aleatória uniforme** em $[-\Delta/2, +\Delta/2]$
- 2 Erros em amostras consecutivas são **não-correlacionados**
- 3 O erro é **independente** do sinal de entrada


Sob essas hipóteses, a função de densidade de probabilidade (PDF) é:

$$p(e_q) = \begin{cases} \frac{1}{\Delta}, & \text{se } -\frac{\Delta}{2} \leq e_q \leq \frac{\Delta}{2} \\ 0, & \text{caso contrário} \end{cases}$$

Cada valor do erro é **igualmente provável** dentro do intervalo.



PDF do Erro de Quantização





Derivação de P_q — Passo 1: Definição Formal

A potência do ruído de quantização P_q é o valor esperado do *quadrado* do erro:

$$P_q = E[e_q^2]$$

Para uma variável aleatória contínua, o valor esperado de uma função $f(e_q)$ é calculado como:

$$E[f(e_q)] = \int_{-\infty}^{+\infty} f(e_q) p(e_q) de_q$$

Portanto, a definição formal de P_q é:

$$P_q = \int_{-\infty}^{+\infty} e_q^2 p(e_q) de_q$$

Interpretação: pesamos e_q^2 pela sua probabilidade $p(e_q)$ e somamos (integramos) sobre todos



Derivação de P_q — Passo 2: Substituição da PDF

Como $p(e_q) = 1/\Delta$ somente no intervalo $[-\Delta/2, +\Delta/2]$ e zero fora dele, podemos restringir os limites da integral:

$$P_q = \int_{-\Delta/2}^{+\Delta/2} e_q^2 \cdot \frac{1}{\Delta} de_q$$

Passo 3 — Resolver a integral

A constante $1/\Delta$ sai da integral:

$$P_q = \frac{1}{\Delta} \int_{-\Delta/2}^{+\Delta/2} e_q^2 de_q$$

A primitiva de e_q^2 é $e_q^3/3$. Aplicando o teorema fundamental do cálculo:



Derivação de P_q — Passo 4: Simplificação

Calculamos os cubos:

$$\left(\frac{\Delta}{2}\right)^3 = \frac{\Delta^3}{8}, \quad \left(-\frac{\Delta}{2}\right)^3 = -\frac{\Delta^3}{8}$$

Substituindo na expressão anterior:

$$P_q = \frac{1}{\Delta} \cdot \frac{\frac{\Delta^3}{8} - \left(-\frac{\Delta^3}{8}\right)}{3} = \frac{1}{\Delta} \cdot \frac{2 \cdot \frac{\Delta^3}{8}}{3} = \frac{1}{\Delta} \cdot \frac{\Delta^3}{12}$$

Cancelando um fator Δ :

$$P_q = \frac{\Delta^2}{12}$$



Relação Sinal-Ruído de Quantização (SQNR)

A qualidade da quantização é medida pelo **SQNR** (*Signal-to-Quantization-Noise Ratio*):

$$\text{SQNR} = \frac{P_s}{P_q} = \frac{P_s}{\Delta^2/12} = \frac{12 P_s}{\Delta^2}$$

Expressando Δ em termos do número de bits n ($L = 2^n$ níveis, faixa V_{pp}):

$$\Delta = \frac{V_{pp}}{2^n} \implies \text{SQNR} = \frac{12 P_s}{(V_{pp}/2^n)^2} = \frac{12 P_s}{V_{pp}^2} \cdot 2^{2n}$$

Observação: $2^{2n} = 4^n$. Adicionar 1 bit multiplica o SQNR por 4 (ou seja, +6 dB).



SQNR para um Sinal Senoidal — Derivação

Caso prático: senoide $g(t) = A \cos(\omega t)$ que ocupa **toda a faixa** do quantizador.

Parâmetros:

$$V_{pp} = A - (-A) = 2A, \quad P_s = \frac{A^2}{2} \quad (\text{potência média da senoide})$$

Substituindo na expressão geral do SQNR:

$$\text{SQNR} = \frac{12 \cdot (A^2/2)}{(2A)^2} \cdot 2^{2n} = \frac{6A^2}{4A^2} \cdot 2^{2n} = \frac{3}{2} \cdot 2^{2n} = 1,5 \cdot 4^n$$

Convertendo para decibéis ($X_{\text{dB}} = 10 \log_{10} X$):

$$\text{SQNR}_{\text{dB}} = 10 \log_{10}(1,5 \cdot 4^n) = 10 \log_{10}(1,5) + n \cdot 10 \log_{10}(4)$$



A Regra dos 6 dB por Bit

Calculando os valores numéricos dos logaritmos:

$$10 \log_{10}(1,5) \approx 1,76 \text{ dB}, \quad 10 \log_{10}(4) \approx 6,02 \text{ dB}$$

Portanto:

$$\text{SQNR}_{\text{dB}} \approx 1,76 + 6,02 n$$

Regra dos 6 dB/bit (senoide em faixa cheia)

$$\text{SQNR}_{\text{dB}} \approx 1,76 + 6,02 n \text{ dB}$$

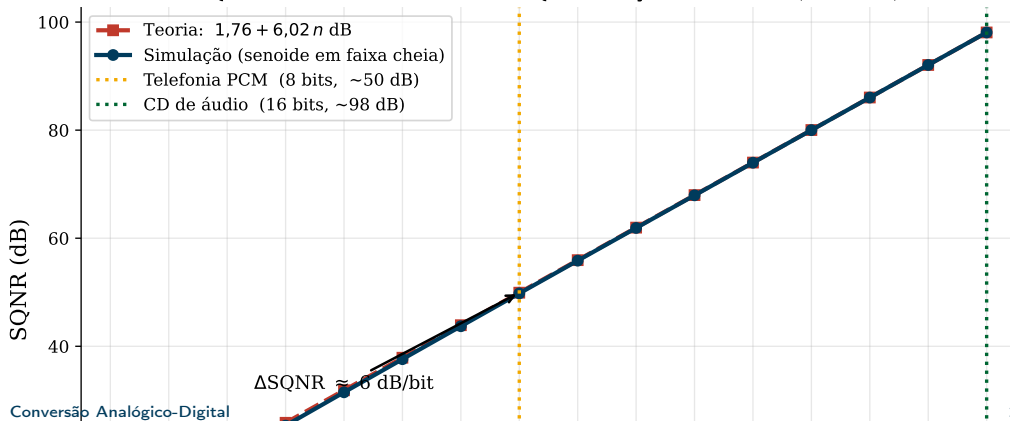
Cada bit adicional eleva o SQNR em $\approx 6 \text{ dB}$.

Exemplos práticos:



SQNR vs. Número de Bits — Confirmação Numérica


SQNR vs. Número de Bits — Quantização Uniforme (Senoide)





Efeito da Resolução na Qualidade do Sinal

Efeito do Número de Bits na Qualidade da Quantização



Com $n = 2$ bits a forma de onda é severamente distorcida. Com $n = 8$ bits a diferença para o sinal original é




Implementação em Python

```
1 import numpy as np
2
3 def quantize_uniform(x, n_bits, v_min=-1.0, v_max=1.0):
4     L = 2**n_bits # numero de niveis
5     delta = (v_max - v_min) / L # tamanho do passo
6     x_c = np.clip(x, v_min, v_max) # limitar faixa
7     idx = np.floor((x_c - v_min)/delta).astype(int)
8     idx = np.clip(idx, 0, L-1)
9     return v_min + (idx + 0.5) * delta # ponto medio
10
11 # Calcular SQNR para varios numeros de bits
12 t = np.linspace(0, 100, 1_000_000)
13 g = np.sin(2*np.pi*t) # senoide em faixa cheia
14
15 for n in [4, 8, 16]:
16     g_q = quantize_uniform(g, n)
17     sqnr = 10 * np.log10(np.mean(g**2) / np.mean((g_q-g)**2))
18     print(f'Conversão Analógica Digital: n={n}, SQNR={sqnr}')
```



A Cadeia ADC Completa



Cada etapa tem parâmetros de projeto que determinam a qualidade e a taxa de bits resultante.



Codificação Binária: PCM

Após a quantização, cada nível $\hat{g}[n]$ recebe uma **palavra binária de n bits** (representação PCM).

Com n bits podemos representar $L = 2^n$ níveis:

$$L = 2^n \iff n = \log_2 L$$

Exemplo com $n = 3$ bits ($L = 8$ níveis):

Índice k	Código binário	Nível \hat{g}
0	000	$V_{\min} + 0,5\Delta$
1	001	$V_{\min} + 1,5\Delta$
\vdots	\vdots	\vdots
7	111	$V_{\max} - 0,5\Delta$



Taxa de Bits e Largura de Banda PCM

A taxa de bits (bit rate) do canal PCM é:

$$R_b = n \cdot f_s \quad [\text{bits/s}]$$

onde n é o número de bits por amostra e f_s é a taxa de amostragem.

A largura de banda mínima necessária para transmitir o PCM (sem inter-símbolos) é:

$$B_{\min} = \frac{R_b}{2} = \frac{n f_s}{2}$$

Compromisso clássico:

- Qualidade alta $\Rightarrow n$ grande $\Rightarrow R_b$ alto \Rightarrow mais largura de banda
- Largura de banda limitada $\Rightarrow n$ reduzido \Rightarrow mais ruído de quantização



Exemplo de Projeto PCM: Telefonia Digital

Parâmetros do canal de voz (ITU-T G.711):

- Largura de banda da voz: $W = 4 \text{ kHz}$
- Taxa de amostragem escolhida: $f_s = 8 \text{ kHz}$ (garante $f_s > 2W$, com margem)
- Resolução: $n = 8 \text{ bits/amostra}$ ($L = 256 \text{ níveis}$)

Taxa de bits por canal:

$$R_b = n \cdot f_s = 8 \times 8\,000 = 64 \text{ kb/s}$$

SQNR máximo (senoide):

$$\text{SQNR}_{\text{dB}} \approx 1,76 + 6,02 \times 8 \approx 50 \text{ dB}$$

Observação: 50 dB é adequado para inteligibilidade da voz, mas ainda abaixo da qualidade de áudio de alta fidelidade (CD: $\sim 98 \text{ dB}$).



Por Que Companding? Motivação

Problema com quantização uniforme para a voz:

A amplitude da voz humana **não tem distribuição uniforme** — amplitudes pequenas são muito mais frequentes do que amplitudes grandes.

Com quantização uniforme:

- Os poucos níveis disponíveis se distribuem **igualmente** por toda a faixa
- A maioria das amostras (pequena amplitude) usa apenas uma **pequena fração** dos níveis
- Para sinais fracos, o SQNR cai drasticamente

Solução: usar passos Δ **menores perto de zero** e maiores para amplitudes altas.

Isso é a **quantização não-uniforme**.

Na prática, implementada via **companding**: **compression** + **expanding**.



O Conceito de Companding

Companding = Compressão + Quantização Uniforme + Expansão



- **Compressor:** amplifica amplitudes pequenas e comprime amplitudes grandes antes da quantização
- **Expansor:** aplica a função inversa no receptor para restaurar as amplitudes originais



Lei μ : Definição Matemática

Padrão nos EUA, Canadá e Japão (ITU-T G.711, $\mu = 255$):

$$C_{\mu}(x) = \text{sgn}(x) \frac{\ln(1 + \mu |x|)}{\ln(1 + \mu)}, \quad |x| \leq 1$$

Propriedades:

- Para $\mu|x| \gg 1$ (sinal grande): $C_{\mu}(x) \approx \text{sgn}(x) \frac{\ln(\mu|x|)}{\ln(1 + \mu)}$ — compressão logarítmica
- Para $\mu|x| \ll 1$ (sinal pequeno): $C_{\mu}(x) \approx x$ — aproximadamente linear
- Caso limite: $\mu \rightarrow 0$ recupera a quantização uniforme

A inversão (expansor) é:

$$C_{\mu}^{-1}(y) = \text{sgn}(y) \frac{(1 + \mu)^{|y|} - 1}{\mu}$$



Lei A: Definição Matemática

Padrão na Europa e em sistemas legados no Brasil (ITU-T G.711, $A = 87,6$):

$$C_A(x) = \text{sgn}(x) \cdot \begin{cases} \frac{A|x|}{1 + \ln A}, & 0 \leq |x| < \frac{1}{A} \\ \frac{1 + \ln(A|x|)}{1 + \ln A}, & \frac{1}{A} \leq |x| \leq 1 \end{cases}$$

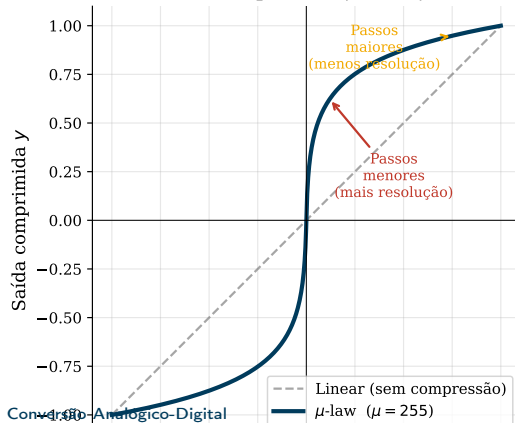
Diferença em relação à lei μ :

- A lei A é **linear** para amplitudes muito pequenas ($|x| < 1/A$) e logarítmica para amplitudes maiores
- A lei μ é logarítmica em toda a faixa
- Ambas garantem SQNR quase constante em uma ampla faixa de níveis de sinal

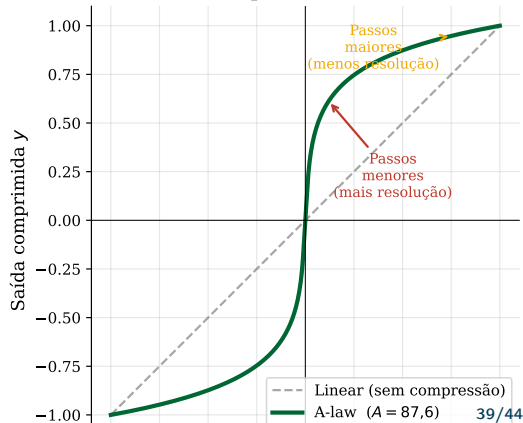


Curvas de Compressão

Curva de Compressão: μ -law ($\mu = 255$)




Curva de Compressão: A-law ($A = 87,6$)





Comparação de SQNR: Uniforme vs. μ -law

SQNR: Quantização Uniforme vs. μ -law ($n = 8$ bits)





Implementação em Python: μ -law Companding

```
1 import numpy as np
2
3 def mu_law_compress(x, mu=255):
4     return np.sign(x) * np.log(1 + mu*np.abs(x)) / np.log(1 + mu)
5
6 def mu_law_expand(y, mu=255):
7     return np.sign(y) * (1/mu) * ((1+mu)**np.abs(y) - 1)
8
9 def quantize_uniform(x, n_bits, v_min=-1.0, v_max=1.0):
10     L = 2**n_bits
11     d = (v_max - v_min) / L
12     idx = np.clip(np.floor((np.clip(x, v_min, v_max)-v_min)/d), 0, L-1)
13     return v_min + (idx.astype(int) + 0.5) * d
14
15 # Pipeline de companding
16 g = 0.05 * np.sin(2*np.pi*np.linspace(0,100,1_000_000))
17 g_comp = mu_law_compress(g) # compressao
18 g_c = quantize_uniform(g_comp, 8) # quantizacao uniforme
```



Resumo: Conversão Analógico-Digital

Resultado 1 — Amostragem (Nyquist-Shannon)

$$f_s > 2W \quad \Rightarrow \quad G_s(f) = f_s \sum_{k=-\infty}^{\infty} G(f - k f_s)$$

Resultado 2 — Ruído de Quantização

$$P_q = \frac{\Delta^2}{12}, \quad \Delta = \frac{V_{pp}}{2^n}$$

Resultado 3 — SQNR (senoide em faixa cheia)



Agradecimentos

Obrigado pela atenção!

Contato:

daniel.araujo@unb.br





Laboratório de Telecomunicações

Universidade de Brasília

Dúvidas?






Referências I

-  J. G. Proakis and M. Salehi, *Communication Systems Engineering*. Upper Saddle River, NJ: Pearson, 2nd ed., 2014.
-  B. P. Lathi and Z. Ding, *Modern Digital and Analog Communication Systems*. New York: Oxford University Press, 4th ed., 2009.
-  C. E. Shannon, "Communication in the presence of noise," *Proceedings of the IRE*, vol. 37, no. 1, pp. 10–21, 1949.
-  H. Nyquist, "Certain topics in telegraph transmission theory," *Transactions of the AIEE*, vol. 47, no. 2, pp. 617–644, 1928.



Referências II

-  W. R. Bennett, "Spectra of quantized signals," *Bell System Technical Journal*, vol. 27, no. 3, pp. 446–472, 1948.
-  A. V. Oppenheim and R. W. Schaffer, *Discrete-Time Signal Processing*. Upper Saddle River, NJ: Prentice Hall, 2nd ed., 1999.
-  S. Haykin and M. Moher, *Communication Systems*. Hoboken, NJ: Wiley, 5th ed., 2013.